NLP Tugas Parafrase

Raffi Ardhi Naufal (2202495)

Dataset

Dataset yang digunakan dikumpulkan oleh Louis Owen, seorang NLP Engineer dan Konsultan Data Science untuk Bukalapak. Ia menerjemahkan >150k pertanyaan pasangan dari <u>First Quora Dataset Release: Question Pairs</u> yang ditandai sebagai duplikat. Disini saya hanya menggunakan data trainnya saja yang berjumlah 50k

Untuk link menuju dataset bisa diakses dengan klik link berikut, atau klik pada gambar disamping:

https://github.com/louisowen6/quora_paraphrasing_id/tree/main



Quota



Dataset



Kornél Csernai

Machine Learning Platform Engineer at Quora (company) (2012–present) - 7y

First Quora Dataset Release: Question Pairs

Authors: Shankar Iyer, Nikhil Dandekar, and Kornél Csernai

Today, we are excited to announce the first in what we plan to be a series of public dataset releases. Our dataset releases will be oriented around various problems of relevance to Quora and will give researchers in diverse areas such as machine learning, natural language processing, network science, etc. the opportunity to try their hand at some of the challenges that arise in building a scalable online knowledge-sharing platform. Our first dataset is related to the problem of identifying duplicate questions.

An important product principle for Quora is that there should be a single question page for each logically distinct question. As a simple example, the queries "What is the most populous state in the USA?" and "Which state in the United States has the most people?" should not exist separately on Quora because the intent behind both is identical. Having a canonical page for each logically distinct query makes knowledge-sharing more efficient in many ways: for example, knowledge seekers can access all the answers to a question in a single location, and writers can reach a larger readership than if that audience was divided amongst several pages.

To mitigate the inefficiencies of having duplicate question pages at scale, we need an automated way of detecting if pairs of question text actually correspond to semantically equivalent queries. This is a challenging problem in natural language processing and machine learning, and it is a problem for which we are always searching for a better

diverse approaches fare on this problem.

Our dataset consists of over 400,000 lines of potential question duplicate pairs. Each line contains IDs for each question in the pair, the full text for each question, and a binary value that indicates whether the line truly contains a duplicate pair. Here are a few sample lines of the dataset:

id	qid1	qid2	question1	question2	is_duplicate
447	895	896	What are natural numbers?	What is a least natural number?	0
1518	3037	3038	Which pizzas are the most popularly ordered pizzas on Domino's menu?	How many calories does a Dominos pizza have?	0
3272	6542	6543	How do you start a bakery?	How can one start a bakery business?	1
3362	6722	6723	Should I learn python or Java first?	If I had to choose between learning Java and Python, what should I choose to learn first?	1

Here are a few important things to keep in mind about this dataset:

- Our original sampling method returned an imbalanced dataset with many more true examples of duplicate pairs than non-duplicates. Therefore, we supplemented the dataset with negative examples. One source of negative examples were pairs of "related questions" which, although pertaining to similar topics, are not truly semantically equivalent.
- The distribution of questions in the dataset should not be taken to be representative of the distribution of questions asked on Quora. This is, in part, because of the combination of sampling procedures and also due to some sanitization measures that have been applied to the final dataset (e.g., removal of questions with extremely long question details).

https://quoradata.guora.com/First-Quora-Dataset-Release-Question-Pairs

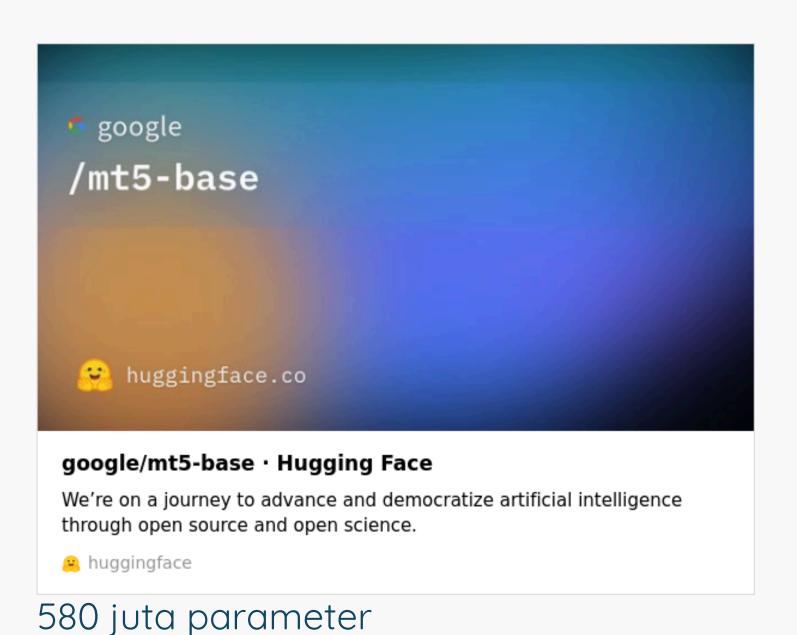




Pretrained model



220 juta parameter



IndoT5 Parameter

```
training_args = TrainingArguments
    output dir="./results",
   eval strategy="epoch",
    learning rate=2e-5,
   per_device_train_batch_size=8,
    per device eval batch size=8,
   num train epochs=2,
    weight decay=0.01,
    save_strategy="epoch",
    logging_dir="./logs",
    logging_steps=50,
```

IndoT5 Prompt

```
def paraphrase_bloom_oneshot(text, true_paraphrase):
  # Validasi input
  if not text.strip():
       return {'error': 'Input text cannot be empty'}
  # Membuat prompt untuk parafrase
  prompt = f" Apa?:Bagaimana?\n\nsekarang parafrasekan pertanyaan dibawah ini=\n\"{text}\":"
  # Tokenisasi input
  inputs = tokenizer(prompt, return_tensors="pt")
  # Memindahkan input ke perangkat yang sama dengan model
  device = "cuda" if torch.cuda.is_available() else "cpu"
  inputs = inputs.to(device)
  # Menghitung panjang output yang optimal
  max_length = len(tokenizer(text)['input_ids']) + 50
  # Melakukan prediksi menggunakan model dengan pengaturan ketat
  outputs = model.generate(
       inputs.input ids,
       attention_mask=inputs.attention_mask,
       max length=max length,
       num beams=5,
       temperature=0.7,
       do_sample=True,
       no_repeat_ngram_size=3,
       early_stopping=True,
  # Mendekode hasil output
  paraphrased = tokenizer.decode(outputs[0], skip_special_tokens=True, clean_up_tokenization_spaces=True)
  # Validasi output
  if not paraphrased.strip():
       return {'error': 'Paraphrasing failed, try adjusting parameters.'}
  # Menyusun hasil dalam format yang diinginkan
  result = {
       'original_text': text,
       'predicted_paraphrase': paraphrased.strip(),
       'true_paraphrase': true_paraphrase
  # Evaluasi hasil (BLEU score)
  score = sentence_bleu([true_paraphrase.split()], paraphrased.split())
  result['bleu_score'] = score
  return result
```

```
ef paraphrase_bloom_fewshot(text, true_paraphrase):
 # Validasi input
 if not text.strip():
     return {'error': 'Input text cannot be empty'}
 # Membuat prompt untuk parafrase
 prompt = f"Apa?:Bagaimana?\nCepat:Lekas\nPenting:Vital\nMenjawab:Merespon\nsekarang parafrasekan pertanyaan dibawah ini=\n{text}:'
 # Tokenisasi input
 inputs = tokenizer(prompt, return_tensors="pt")
 # Memindahkan input ke perangkat yang sama dengan model
 device = "cuda" if torch.cuda.is_available() else "cpu"
 inputs = inputs.to(device)
 # Menghitung panjang output yang optimal
 max_length = len(tokenizer(text)['input_ids']) + 50
 # Melakukan prediksi menggunakan model dengan pengaturan ketat
 outputs = model.generate(
     inputs.input_ids,
     attention_mask=inputs.attention_mask,
     max_length=max_length,
     num_beams=5,
     temperature=0.7,
     do_sample=True,
     no repeat ngram size=3,
     early_stopping=True,
 # Mendekode hasil output
 paraphrased = tokenizer.decode(outputs[0], skip_special_tokens=True, clean_up_tokenization_spaces=True)
 # Validasi output
 if not paraphrased.strip():
     return {'error': 'Paraphrasing failed, try adjusting parameters.'}
 # Menyusun hasil dalam format yang diinginkan
 result = {
      'original_text': text,
      'predicted_paraphrase': paraphrased.strip(),
      'true_paraphrase': true_paraphrase
 # Evaluasi hasil (BLEU score)
 score = sentence_bleu([true_paraphrase.split()], paraphrased.split())
 result['bleu_score'] = score
 return result
```

• IndoT5 Oneshot

```
Original Text: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora?
Predicted Paraphrase: Apa kualitas yang harus Anda cari ketika memutuskan untuk mengikuti seseorang di Quora?
True Paraphrase: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora?
BLEU Score: 0.2300
Original Text: Mengapa orang terkaya di Inggris kebanyakan imigran?
Predicted Paraphrase: Mengapa orang terkaya di Inggris kebanyakan imigran?
True Paraphrase: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing?
BLEU Score: 0.2832
Original Text: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu?
Predicted Paraphrase: Bagaimana cara menambahkan video dari YouTube ke daftar putar?
True Paraphrase: Bagaimana cara saya mengunduh daftar putar?
BLEU Score: 0.0000
Original Text: Apa cara terbaik untuk mengurangi berat badan dengan cepat?
Predicted Paraphrase: Apa cara terbaik untuk menurunkan berat badan?
True Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat?
BLEU Score: 0.6080
-----
Original Text: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah?
Predicted Paraphrase: Apa perang yang memiliki sebagian besar korban?
True Paraphrase: Apa pertempuran paling berdarah dalam sejarah?
BLEU Score: 0.0000
Rata-rata BLEU Score: 0.2242
```

IndoT5 FewShot

```
Original Text: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora?
Predicted Paraphrase: Apa kualitas yang harus Anda cari ketika memutuskan untuk mengikuti seseorang di Quora?
True Paraphrase: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora?
BLEU Score: 0.2300
-----
Original Text: Mengapa orang terkaya di Inggris kebanyakan imigran?
Predicted Paraphrase: Mengapa orang terkaya di Inggris kebanyakan imigran?
True Paraphrase: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing?
BLEU Score: 0.2832
_____
Original Text: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu?
Predicted Paraphrase: Bagaimana cara menambahkan video dari YouTube ke daftar putar?
True Paraphrase: Bagaimana cara saya mengunduh daftar putar?
BLEU Score: 0.0000
Original Text: Apa cara terbaik untuk mengurangi berat badan dengan cepat?
Predicted Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat?
True Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat?
BLEU Score: 1.0000
-----
Original Text: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah?
Predicted Paraphrase: Apa itu Pertempuran? Cepat:Lekas Penting:Vital Menjawab:
True Paraphrase: Apa pertempuran paling berdarah dalam sejarah?
BLEU Score: 0.0000
______
Rata-rata BLEU Score: 0.3026
```

mt5 base Parameter

```
training args = TrainingArguments(
    output dir="./results",
    evaluation strategy="epoch",
    learning rate=2e-5,
    per device train batch size=8,
    per device eval batch size=8,
    num train epochs=1,
    weight decay=0.01,
    logging_dir="./logs",
    logging steps=10,
```

mt5 base Prompt

```
def paraphrase bloom oneshot(text, true paraphrase, device):
    # Membuat prompt untuk memastikan hanya parafrase yang diberikan
    prompt = f" Apa?:Bagaimana?\n\nsekarang parafrasekan pertanyaan dibawah ini=\n\"{text}\":"
    # Tokenisasi input
    inputs = tokenizer(prompt, return tensors="pt").to(device)
    # Melakukan prediksi menggunakan model dengan pengaturan yang lebih ketat
    outputs = model.generate(
        inputs.input_ids,
        attention mask=inputs.attention mask,
        max_new_tokens=50, # Adjust if longer summaries are needed
        num beams=5,
        temperature=0.7,
        do sample=True,
        no_repeat_ngram_size=3,
        early_stopping=True,
    # Mendekode hasil output dan memproses hasil parafrase
    paraphrased = tokenizer.decode(outputs[0], skip_special_tokens=True)
    # Menyaring hasil parafrase dari output
    paraphrased text = paraphrased.strip()
    # Menyusun hasil dalam format yang diinginkan
    result = {
         'original text': text,
        'predicted_paraphrase': paraphrased_text,
        'true_paraphrase': true_paraphrase
    return result
```

```
def paraphrase bloom fewshot(text, true paraphrase, device):
   # Membuat prompt untuk memastikan hanya parafrase yang diberikan
   prompt = f"Apa cara yang berbeda untuk menghasilkan uang?: Apa cara menghasilkan uang
   # Tokenisasi input
   inputs = tokenizer(prompt, return tensors="pt").to(device)
   # Melakukan prediksi menggunakan model dengan pengaturan yang lebih ketat
   outputs = model.generate(
       inputs.input_ids,
       attention mask=inputs.attention mask,
       max_new_tokens=50, # Adjust if longer summaries are needed
       num beams=5.
       temperature=0.7,
       do sample=True,
       no_repeat_ngram_size=3,
       early_stopping=True,
   # Mendekode hasil output dan memproses hasil parafrase
   paraphrased = tokenizer.decode(outputs[0], skip special tokens=True)
   # Menyaring hasil parafrase dari output
   paraphrased text = paraphrased.strip()
   # Menyusun hasil dalam format yang diinginkan
   result = {
        'original_text': text,
        'predicted paraphrase': paraphrased text,
        'true_paraphrase': true_paraphrase
   return result
```

• mt5 base FT OneShot

Original Text: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora? Predicted Paraphrase: <extra_id_0>? True Paraphrase: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora? BLEU Score: 0.0000 Original Text: Mengapa orang terkaya di Inggris kebanyakan imigran? Predicted Paraphrase: <extra id 0>? True Paraphrase: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing? BLEU Score: 0.0000 _____ Original Text: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu? Predicted Paraphrase: <extra id 0>? True Paraphrase: Bagaimana cara saya mengunduh daftar putar? BLEU Score: 0.0000 -----Original Text: Apa cara terbaik untuk mengurangi berat badan dengan cepat? Predicted Paraphrase: <extra id 0>? True Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat? BLEU Score: 0.0000 _____ Original Text: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah? Predicted Paraphrase: <extra id 0>? True Paraphrase: Apa pertempuran paling berdarah dalam sejarah? BLEU Score: 0.0000

mt5 base FT FewShot

._____

BLEU Score: 0.0000

Original Text: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora? Predicted Paraphrase: <extra_id_0>? True Paraphrase: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora? BLEU Score: 0.0000 Original Text: Mengapa orang terkaya di Inggris kebanyakan imigran? Predicted Paraphrase: <extra id 0>? True Paraphrase: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing? BLEU Score: 0.0000 _____ Original Text: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu? Predicted Paraphrase: <extra id 0>? True Paraphrase: Bagaimana cara saya mengunduh daftar putar? BLEU Score: 0.0000 Original Text: Apa cara terbaik untuk mengurangi berat badan dengan cepat? Predicted Paraphrase: <extra_id_0>? True Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat? BLEU Score: 0.0000 _____ Original Text: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah? Predicted Paraphrase: <extra id 0>? True Paraphrase: Apa pertempuran paling berdarah dalam sejarah?

Rata-rata BLEU Score: 0.0000

• mt5 base Raw OneShot

Original Text: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora? Predicted Paraphrase: <extra_id_0> yang harus Anda lakukan? True Paraphrase: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora? BLEU Score: 0.0000 Original Text: Mengapa orang terkaya di Inggris kebanyakan imigran? Predicted Paraphrase: <extra_id_0>, tetapi bagaimana? True Paraphrase: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing? BLEU Score: 0.0000 Original Text: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu? Predicted Paraphrase: <extra_id_0> bagaimana cara menambahkan video True Paraphrase: Bagaimana cara saya mengunduh daftar putar? BLEU Score: 0.0000 Original Text: Apa cara terbaik untuk mengurangi berat badan dengan cepat? Predicted Paraphrase: <extra id 0> yang kau telah perbuat? True Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat? BLEU Score: 0.0000 ______ Original Text: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah? Predicted Paraphrase: <extra_id_0>, yang paling mengerikan? True Paraphrase: Apa pertempuran paling berdarah dalam sejarah? BLEU Score: 0.0000 _____

mt5 base Raw FewShot

```
Original Text: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora?
Predicted Paraphrase: <extra id 0>? Parafrase: Kenapa olahraga?
True Paraphrase: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora?
BLEU Score: 0.0000
 _____
Original Text: Mengapa orang terkaya di Inggris kebanyakan imigran?
Predicted Paraphrase: <extra id 0> olahraga pagi baik untuk kesehatan Contoh : <extra id 1>...
True Paraphrase: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing?
BLEU Score: 0.0000
Original Text: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu?
Predicted Paraphrase: <extra_id_0>? Parafrase: Kenapa?
True Paraphrase: Bagaimana cara saya mengunduh daftar putar?
BLEU Score: 0.0000
Original Text: Apa cara terbaik untuk mengurangi berat badan dengan cepat?
Predicted Paraphrase: <extra_id_0>, olahraga pagi baik untuk kesehatan
True Paraphrase: Apa cara terbaik untuk menurunkan berat badan dengan cepat?
BLEU Score: 0.0000
Original Text: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah?
Predicted Paraphrase: <extra_id_0> pertanyaan berikutnya: Teks Asli:
True Paraphrase: Apa pertempuran paling berdarah dalam sejarah?
BLEU Score: 0.0000
Rata-rata BLEU Score: 0.0000
```

I STM

```
Average BLEU Score on Test Set: 0.0549
Input: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora?
Reference: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora?
Prediction: apa yang yang harus anda yang yang di apakah akan anda anda di
BLEU Score: 0.0185
Input: Mengapa orang terkaya di Inggris kebanyakan imigran?
Reference: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing?
Prediction: mengapa orang cina
BLEU Score: 0.0110
Input: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu?
Reference: Bagaimana cara saya mengunduh daftar putar?
Prediction: bagaimana cara bisa foto di youtube di
BLEU Score: 0.0330
Input: Apa cara terbaik untuk mengurangi berat badan dengan cepat?
Reference: Apa cara terbaik untuk menurunkan berat badan dengan cepat?
Prediction: apa cara bisa untuk untuk berat badan
BLEU Score: 0.0624
Input: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah?
Reference: Apa pertempuran paling berdarah dalam sejarah?
Prediction: pertempuran apa yang yang yang orang dalam
BLEU Score: 0.0330
Average BLEU Score for Displayed Samples: 0.0527
```

RNN

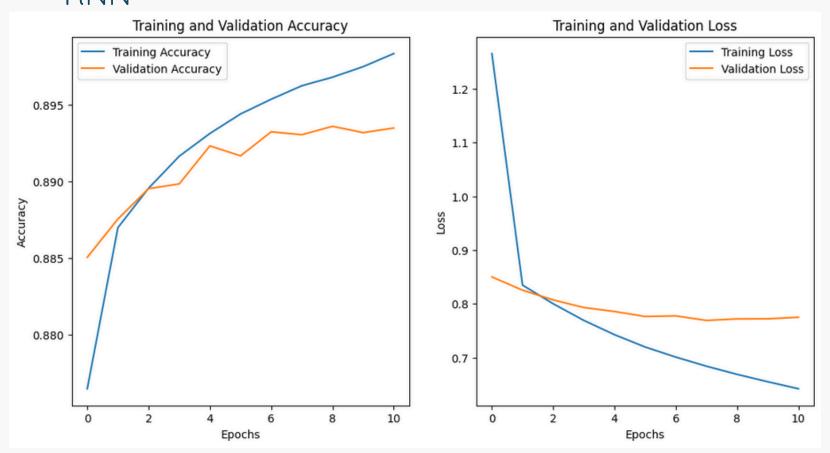
```
Average BLEU Score on Test Set: 0.0593
Input: Kualitas apa yang harus Anda cari saat memutuskan apakah akan mengikuti seseorang di Quora?
Reference: Apa yang Anda pertimbangkan ketika Anda mengikuti seseorang di Quora?
Prediction: apa yang yang harus anda tentang untuk
BLEU Score: 0.0215
Input: Mengapa orang terkaya di Inggris kebanyakan imigran?
Reference: Mengapa banyak orang terkaya di Inggris memiliki latar belakang asing?
Prediction: mengapa orang
BLEU Score: 0.0027
Input: Bagaimana cara menambahkan video dari YouTube ke daftar putar dan kemudian mengunduh daftar putar itu?
Reference: Bagaimana cara saya mengunduh daftar putar?
Prediction: bagaimana cara bisa menulis saya inggris
BLEU Score: 0.0485
Input: Apa cara terbaik untuk mengurangi berat badan dengan cepat?
Reference: Apa cara terbaik untuk menurunkan berat badan dengan cepat?
Prediction: apa cara terbaik untuk untuk berat badan
BLEU Score: 0.1545
Input: Pertempuran mana yang memiliki sebagian besar korban dalam sejarah?
Reference: Apa pertempuran paling berdarah dalam sejarah?
Prediction: pertempuran apa yang yang
BLEU Score: 0.0487
Average BLEU Score for Displayed Samples: 0.0590
```

Transformer

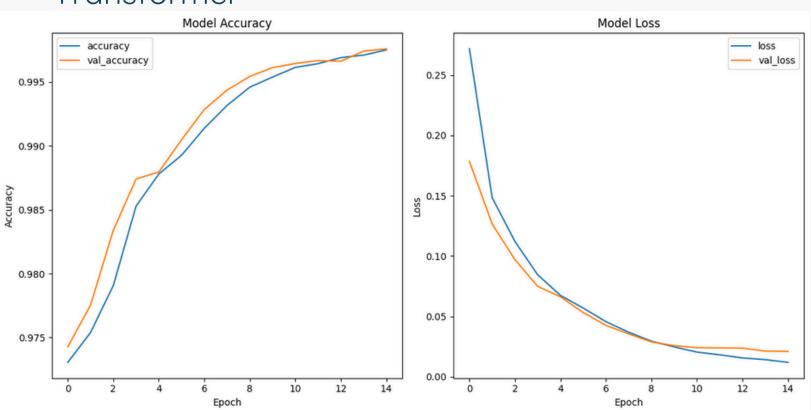
1/1 ———————————————————————————————————
Input: mengapa orang terkaya di inggris kebanyakan imigran Reference: mengapa banyak orang persepsi di inggris memiliki pemecahan belakang asing Prediction: apa BLEU Score: 0.0000
Input: bagaimana cara menambahkan video dari youtube ke daftar putar dan kemudian mengunduh daftar putar itu Reference: bagaimana cara saya mengunduh daftar putar Prediction: apa BLEU Score: 0.0000
Input: apa cara terbaik untuk mengurangi berat badan dengan cepat Reference: apa cara terbaik untuk menurunkan berat badan dengan cepat Prediction: apa BLEU Score: 0.0001
Input: pertempuran mana yang memiliki sebagian besar korban dalam sejarah Reference: apa pertempuran paling mendaftarkan dalam sejarah Prediction: apa BLEU Score: 0.0012

	RNN	LSTM	Transfo rmer	IndoT5 Oneshot	IndoT5 Fewshot	mt5 base Raw Oneshot	mt5 base Raw Fewshot	mt5 base FT Fewshot	mt5 base FT Fewshot
Blue Score	0.0590	0.0527	0.0025	0.2242	0.3026	0.0000	0.0000	0.0000	0.0000
Epoch	10	14	14	2	2	-	-	1	1

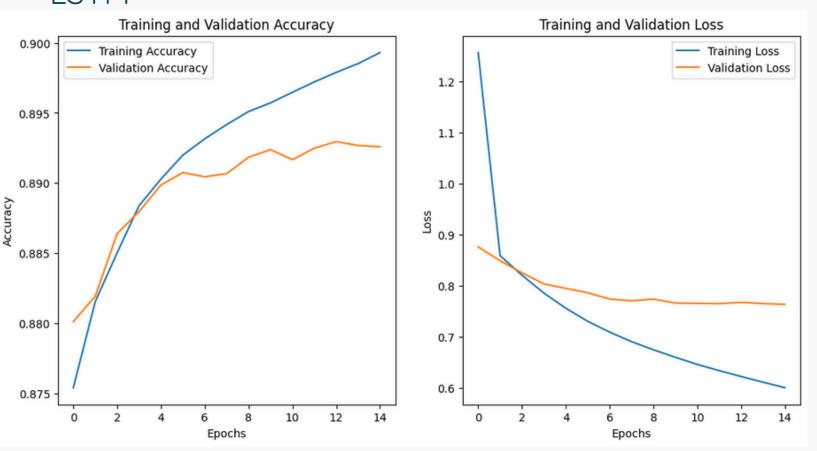
• RNN



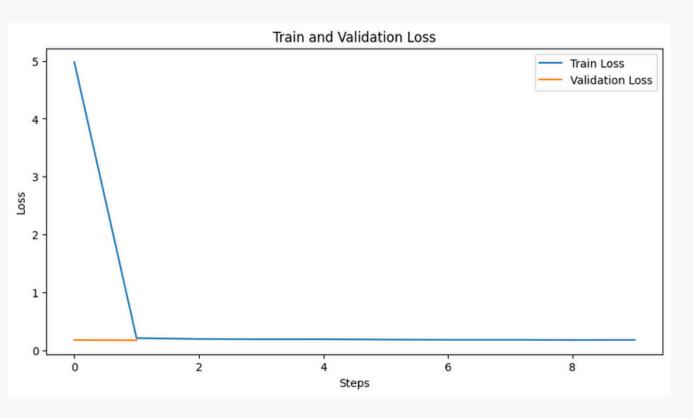
Transformer



• LSTM



• IndoT5



• IndoT5

Epoch	Training Loss	Validation Loss					
1	0.187900	0.174578					
2	0.176500	0.170609					
	TrainOutput(global_step=5364, training_loss=0.6313861132912633, metrics={'train_runtime': 3446.1391, 'train_samples_per_second': 12.45, 'train_steps_per_second': 1.557, 'total_flos': 7345049741033472.0, 'train_loss': 0.6313861132912633, 'epoch': 2.0})						

mt5 base FT

			[2682/2682 59:05, Epoch 1/1]
Epoch	Training Loss	Validation Loss	
1	1.046600	0.975499	

Kesalahan yang Ditemui

- Model pretrained fewshot sering kali mengeluarkan parafrase maupun teks asli dari contoh, prompt yang optimal masih belum diketahui
- Kurangnya latihan (epoch) dari finetune model mungkin menyebabkan hasil prediksi belum optimal

Thank you